

programmation et SEO : Balise canonical

La balise 'canonical' existe depuis 2009, invention de Google, et elle a 2 fonctions :

- indiquer un contenu dupliqué sur un site (duplication locale)
- fournir au moteur de recherche l'URL canonique (officielle, unique) d'une page face à des contenus dupliqués sur le site.

Un site doit avoir des pages ayant chacune un contenu unique.

Bien sur, les menus, les colonnes de droites, les entêtes, les footers de page sont donc des duplicates partiels que Google ignore.

Il reste donc la partie centrale sensée être unique et apporter une valeur ajoutée à l'internaute sous peine de ne pas être indexée.

lorsque deux ou plusieurs pages sur un même site reprennent un contenu identique ou similaire, quel document est le "canonique", c'est-à-dire celui que le moteur de recherche doit considérer comme le plus pertinent, celui qui est à LA source de l'information unique.

La balise canonical indique l'URL de la page à indexer

La forme d'une balise "canonical" est la suivante : `<link rel="canonical" href="https://www.site-exemple.com/page-uniqueEtCanonique" />`

si un contenu est dupliqué sur, disons, 8 pages, c'est à dire avec 8 URL distinctes, le codeur peut décider et coder pour que ces pages aient la même balise canonical.

Exercice : algorithmes pour décider comment affecter une valeur à une balise canonical.

Exercice de compréhension : pourquoi est-il préférable que le propriétaire du site choisisse la page canonical ?

Si une page A (<https://www.site-exemple.com/page-A.html>) reprend le contenu d'une page B (<https://www.site-exemple.com/page-B.html>) sur le même site et veut l'indiquer aux moteurs, la page A contiendra la balise suivante (indiquant qu'elle est dupliquée de B) : `<link rel="canonical" href="https://www.site-exemple.com/page-B.html/" />`

La page prise en compte par Google sera alors la page B.

La page B, pour sa part, contiendra la balise suivante (identique) (éviter 2 URL pour un même contenu sur un même site) : `<link rel="canonical" href="https://www.site-exemple.com/page-B.html/" />` Chaque page web d'un site doit donc contenir une balise "canonical" : - Pointant vers la page canonique si le contenu est dupliqué. - Pointant vers elle-même si la page est canonique.

Erreurs à éviter :

<https://webmasters.googleblog.com/2013/04/5-common-mistakes-with-relcanonical.html>

- Les deux pages doivent avoir un contenu identique ou très proche.
- L'URL indiquée dans la balise (celle de la page canonique) existe et, par exemple, n'est pas redirigée. - Cette page canonique ne contient pas une balise meta robots "noindex".
- Assurez-vous que la page canonique est bien celle que vous désirez voir affichée dans les résultats de Google (à la place de la page dupliquée).

- La balise "canonical" peut se trouver dans la partie "Head" du code source de la page dupliquée ou dans l'en-tête HTTP.
- Ne spécifiez qu'une balise "canonical" dans la page; S'il en existe plusieurs, elles seront toutes ignorées.
- Ne pas insérez canonical dans des pages gérées avec des pages paginées
- confusion dans les URL cibles => toujours en absolu, jamais en relatif
-

Balises next et prev

Elles servent à indiquer la pagination à Google. Cela lui permet de reconstituer un « grand contenu » composé de N pages successives.

À savoir coder ou à avoir le plugin adéquat

Redirection HTTP 301

Http : // monsite.fr

http : // www. monsite.fr ???

301 de toutes les variantes de nom de domaine vers la seule à utiliser en .htaccess

Redirect 301 /index.html /accueil.php : cette ligne dans un fichier .htaccess redirige l'internaute de index.html vers accueil.php.

Sécurité informatique : .HTACCESS / .HTPASSWD

AuthUserFile /repertoire_protege/.htpasswd

AuthGroupFile /dev/null

AuthName groupe_1

AuthType Basic

require user gilles

".htpasswd" est placé dans le répertoire "/repertoire_protege", il contient nos couples de id/password pour chaque utilisateur. (attention : .htaccess est donc placé un cran au dessus !)

Nous verrons ce fichier plus en avant dans ce doc;

nous n'utilisons pas de fichier définissant des groupes d'utilisateurs => "/dev/null" correspond au device null sous Unix, càd à quelque chose d'inexistant).

"groupe_1" est le nom de cette authentification (éviter les espaces donc _)

"Basic" est le type d'authentification.

l'utilisateur "gilles" (attention à la casse) est seul autorisé à accéder à notre répertoire

exercice : coder un .htaccess avec de la sécurité d'accès à un site web : test / test

explications sur comment organiser une succession de .htaccess / .htpasswd pour protéger un serveur, un ensemble de répertoires ... au tableau.

"/repertoire_protege => il contient un .htaccess : Deny from All => ainsi seul le système peut avoir

accès à ce fichier et que lui !

.htpasswd : contient le id et le mot de passe CRYPTÉ

gilles:7ZdRt82R5xY

d'où l'intérêt de le mettre dans un répertoire dédié inaccessible depuis le web, sinon des outils pourraient tenter (et réussir) de le casser.

Autres choses à savoir :

Deny from 192.168.1.2 que cette adresse IP bloquée => pratique quand on a un hacker qui insiste

Deny from 192.168 cette plage d'adresse IP interdite

Deny from test.monsite.fr bloque requête de ce nom de domaine

exercice : à part deny, que pourrais je mettre ?

Réponse :

order deny,allow

deny from all

Allow from 192.168.1.2

FAIBLESSES de HTACCESS

HTTP (sans le S à http)

il est aisé de casser un mot de passe transitant dans http

=> passer à HTTPS

Trop d'outil du système donne accès au répertoire protégé : telnet / tout logiciel aidé de l'autorisation du système via SU etc. (cp ...)

plus de détail : <https://www.securiteinfo.com/conseils/htaccess.shtml>

réécriture URL via .htaccess

Simple :

RewriteEngine On

RewriteRule .* test.php

redirige chaque requête sur le script **test.php** .

RewriteEngine On

RewriteRule test /nom_repertoire/test.php

Cette formule ré écrit chaque requête **/test** sur le script **/nom_repertoire/testing.php** .

RewriteEngine on

RewriteCond %{HTTP_HOST} ^exemple.com\$

RewriteRule ^(.*) http://www.exemple.com/\$1 [QSA,L,R=301]

force l'adresse de votre site à être de type www.exemple.com, utile pour le référencement

Options +FollowSymlinks

RewriteEngine On

RewriteRule ^bof.html\$ test.html [L]

« bof.html » (donc est exactement ce fichier), on affiche le fichier « test.html » et on stoppe la réécriture (le drapeau [L] => "Last")

Erreur 500 => vous vous êtes planté dans la programmation.

Syntaxe

RewriteRule URL_a_réécrire URL_réécrite [drapeau]

exo : décrypter ceci ?

RewriteRule ^article-([0-9]+)-([0-9]+)\.html\$ /articles/article.php?id=\$1&rubrique=\$2 [L]

progressivement

syntaxe

RewriteCond %{VARIABLE_A_TESTER} Condition_a_tester [drapeau]

« Chaîne_de_test » : HTTP_USER_AGENT HTTP_REFERER HTTP_COOKIE
HTTP_FORWARDED

un bon site de tuto : https://craym.eu/tutoriels/referencement/url_rewriting.html

RewriteCond %{VARIABLE_A_TESTER} Condition_a_tester [drapeau]

RewriteEngine on

RewriteCond %{HTTP_REFERER} !^\$

RewriteCond %{REQUEST_FILENAME} (.*)\.jpg\$

RewriteRule %1 dossier_image/%1.jpg

on vérifie que la requête provient de la même page (HTTP_REFERER est vide) ET que la requête est une image.

Si c'est le cas, alors on redirige l'adresse de l'image demandée sur le bon dossier : « dossier_image/ » où le serveur trouvera le bon fichier.